

Contaminación del aire en Lima Metropolitana

“Dos Limas, un mismo cielo”: clustering y predicción de calidad del aire

Cartagena Valera Brush, Davis Leonardo
Chilon Tintaya, Monica Isabel

Lavado Torres, Gianmarco Gabriel
Huayta Esteban, Piero Alessandro

Minería de Datos – UNMSM-FISI, 2026-I

Fuente de datos: SENAMHI – *Monitoreo de los contaminantes del aire en Lima Metropolitana*¹ (Plataforma Nacional de Datos Abiertos del Perú). Dataset horario, 10 estaciones, ventana analizada 2014-10-01 a 2020-09-30 (514,680 registros hora-estación).

1 Contexto y problema

Lima Metropolitana no respira el mismo aire en todas sus zonas. Los datos horarios de material particulado fino (PM2.5) publicados por SENAMHI para 10 estaciones de monitoreo muestran una brecha sostenida entre distritos: estaciones del este y norte de la ciudad –ATE (39.4 $\mu\text{g}/\text{m}^3$), Puente Piedra (31.2), San Juan de Lurigancho (29.9), Santa Anita (29.1) y Huachipa (28.3)– registran un promedio histórico de PM2.5 por encima del Estándar de Calidad Ambiental (ECA) anual de 25 $\mu\text{g}/\text{m}^3$ fijado por el D.S. N.º 003-2017-MINAM, mientras que las 5 estaciones restantes (Villa María del Triunfo, Carabayllo, Campo de Marte, San Martín de Porres, San Borja) quedan por debajo; ninguna estación supera, en promedio, el ECA de 24h (50 $\mu\text{g}/\text{m}^3$). Esta desigualdad espacial es la tesis que atraviesa el proyecto: *dos Limas, un mismo cielo*.

El problema es relevante para el contexto peruano en dos frentes. Primero, de **salud pública**: la exposición crónica a PM2.5 está asociada por la evidencia científica internacional a enfermedades respiratorias y cardiovasculares, y las zonas más expuestas de Lima no cuentan hoy con un sistema accesible que traduzca los datos crudos de SENAMHI en una alerta interpretable. Segundo, de **gestión ambiental**: sin una segmentación clara de qué estaciones concentran el problema ni un pronóstico de su evolución estacional (el llamado “invierno limeño”), es difícil priorizar dónde enfocar campañas de mitigación o monitoreo adicional con recursos limitados.

A quién beneficia: autoridades ambientales y de salud (MINAM, SENAMHI, gobiernos locales de los distritos más expuestos) que necesitan priorizar intervención con datos, y la ciudadanía de las zonas identificadas como de mayor riesgo, que hoy no tiene acceso a una herramienta simple para consultar el estado de la calidad del aire de su zona.

Costo de no resolverlo: sin segmentación ni pronóstico, la asignación de recursos de monitoreo y mitigación se hace a ciegas, tratando a Lima como una sola zona homogénea cuando la evidencia (Sección 4 y 5) muestra que no lo es. Un sistema que clasifique horas de riesgo y proyecte la tendencia mensual permite, como mínimo, anticipar picos estacionales con semanas de margen en vez de reaccionar después del hecho.

2 Objetivos SMART

Los siguientes objetivos están anclados a resultados ya obtenidos y verificables en el proyecto (models/metrics.json, models/forecast_metrics.json y el código fuente citado), no son metas

¹<https://www.datosabiertos.gob.pe/dataset/datos-horarios-de-contaminantes-del-aire-en-lima-metropolitana-servicio-nacional-de>

genéricas de relleno.

- O1. Clasificación de horas de alta contaminación.** Entrenar y desplegar, para la presentación de la semana 16 (S16) del curso, un clasificador binario de horas con PM2.5 por encima del ECA de 24h ($50 \mu\text{g}/\text{m}^3$) que alcance un $F1 \geq 0.40$ en la clase minoritaria sobre un hold-out cronológico agrupado por día calendario, auditable en `models/metrics.json`. *Estado: ya cumplido* – el modelo desplegado (`rf_classweight`) obtiene $F1 = 0.419$ (Sección 4).
- O2. Pronóstico mensual de PM2.5.** Producir, para S16, un pronóstico de al menos 4 períodos futuros de PM2.5 mensual con un error porcentual medio (MAPE) $\leq 10\%$ sobre un hold-out de 12 meses sin barajar, auditable en `models/forecast_metrics.json`. *Estado: ya cumplido* – el modelo ganador (naive estacional) obtiene MAPE = 8.18% en un pronóstico de 6 meses (Sección 4).
- O3. Segmentación espacial de estaciones.** Agrupar, para S16, las 10 estaciones SENAMHI en al menos 2 clusters con coeficiente de silueta positivo, para sustentar cuantitativamente la desigualdad de “las dos Limas” entre zonas. *Estado: ya cumplido* – K-means con $k = 2$ sobre el perfil estandarizado de contaminantes por estación obtiene silueta = 0.330 (inercia = 30.1).
- O4. Trazabilidad de consultas.** Implementar, para S16, un CRUD accesible desde el navegador sin credenciales que registre cada consulta de predicción (entrada + resultado del Objetivo O1) con timestamp automático, permitiendo editar y eliminar registros. *Estado: ya cumplido* – CRUD funcional sobre SQLite (`data/consultas.db`) con las 4 operaciones, integrado como Panel 4 de `app.py`.

3 KPIs del proyecto

Todos los valores de *baseline* de esta tabla provienen directamente de los artefactos versionados del proyecto (`models/metrics.json` y `models/forecast_metrics.json`, generados el 2026-07-21) o de un cálculo en vivo sobre `data/air_contamination_clean.parquet`; ninguno es inventado. Las *metas* son objetivos de mejora incremental sobre ese baseline, propuestos como referencia para las próximas iteraciones del proyecto.

KPI	Baseline (real)	Meta
F1 de la clase “alta contaminación” (modelo desplegado, <code>rf_classweight</code>)	0.419	≥ 0.45
Recall de la clase “alta contaminación” (mismo modelo)	77.8%	$\geq 85\%$
MAPE del pronóstico mensual de PM2.5 (modelo ganador, naive estacional, hold-out 12 meses)	8.18%	$\leq 7\%$
Cobertura de dato medido (no imputado) de PM2.5, a nivel de todo el dataset limpio	62.2% / 37.8% imp.	imp. $\leq 30\%$

Tabla 1: KPIs propuestos con baseline real verificado y metas de mejora incremental para las próximas iteraciones del proyecto.

El cuarto KPI (cobertura de dato medido) es distinto de los otros tres: no depende de un modelo, sino de la infraestructura de monitoreo de SENAMHI – mejorarlo requeriría menos huecos de sensor en campo, no un cambio de algoritmo. Se incluye porque delimita qué tan confiables son los otros KPIs: un F1 o un MAPE calculados sobre una serie con 37.8% de datos imputados heredan parte de esa incertidumbre.

4 Justificación de modelos

4.1 Segmentación de estaciones: selección de k

La unidad de clustering es la *estación*, no la hora: cada uno de los 10 puntos que entra a K-means es el promedio histórico de sus 6 contaminantes (PM10, PM2.5, SO₂, NO₂, O₃, CO) a lo largo de toda la ventana analizada. Los 6 promedios se estandarizan con `StandardScaler` antes de agrupar, para que ningún contaminante domine el agrupamiento solo por su escala (CO, en $\mu\text{g}/\text{m}^3$, tiene un orden de magnitud mucho mayor que el resto). Se usa `SEED = 96` (la misma semilla que el resto del proyecto) para que el resultado sea reproducible.

Se eligió $k = 2$: con ese valor la silueta es 0.330 (positiva, clusters razonablemente separados), frente a 0.297 con $k = 3$ – sumar un tercer grupo no mejora la separación, solo fragmenta las 10 estaciones en particiones más pequeñas y ruidosas. Esta silueta se calcula sobre solo 10 puntos (una fila por estación): con tan pocos puntos, subir k tiende a dejar grupos de 1–2 miembros, lo que la vuelve más ruidosa, y por eso **no es directamente comparable** con la silueta calculada a nivel de fila-hora en el notebook de EDA (~515,000 registros) – aunque en la práctica ambas coinciden en que $k = 2$ es el mejor valor.

Cluster	pm_10	pm_25	so2	no2	o3	co
0 (baja contaminación)	65.0	19.3	7.0	19.3	16.6	678.6
1 (alta contaminación)	92.7	31.6	14.9	30.7	12.3	1026.6

Tabla 2: Perfil promedio de contaminantes por cluster ($k = 2$), unidades originales de cada contaminante.

Conclusión razonada. El cluster de alta contaminación es entre un 40% y más del doble más alto que el de baja en todos los contaminantes, con una excepción: el O₃, más bajo (12.3 vs. 16.6) – consistente con que el ozono es un contaminante secundario y fotoquímico (se forma en la atmósfera bajo luz solar y tiende a consumirse por titulación con los óxidos de nitrógeno del tráfico), no uno que se emita directamente como los demás. Las 5 estaciones del cluster de alta contaminación (ATE, Huachipa, Puente Piedra, San Juan de Lurigancho, Santa Anita) coinciden *exactamente* con las 5 estaciones que superan el ECA anual de 25 $\mu\text{g}/\text{m}^3$ en la Sección 1 – dos métodos completamente distintos (clustering no supervisado vs. un umbral regulatorio fijo) llegando al mismo resultado.

4.2 Clasificación: RF (class_weight) vs. XGBoost vs. RF+SMOTE

La variable objetivo ($\text{PM}_{2.5} > 50 \mu\text{g}/\text{m}^3$, ECA de 24h) está fuertemente desbalanceada: solo el 7.9% de las horas medidas son “alta contaminación”. Se entrenaron y evaluaron tres estrategias sobre el mismo hold-out (30% de test, separado por día calendario para no filtrar horas del mismo día entre train y test):

Modelo	Accuracy	ROC-AUC	F1 (alta)	Recall (alta)	Precision (alta)
RF + class_weight (ganador)	0.828	0.898	0.419	0.778	0.287
XGBoost + scale_pos_weight	0.808	0.896	0.402	0.808	0.267
RF + SMOTE (referencia, no desplegado)	0.835	0.895	0.425	0.763	0.294

Tabla 3: Métricas sobre la clase minoritaria (“alta contaminación”), $n_{\text{test}} = 93,793$ horas.

Conclusión razonada. El modelo se elige por **F1 de la clase minoritaria**, no por accuracy: en un problema con 92.1% de horas “baja” un clasificador trivial que siempre prediga “baja” ya obtendría accuracy alto sin ser útil. El costo de no avisar una hora contaminada (falso negativo) es mayor que el de una falsa alarma (falso positivo), por lo que el recall de la clase alta pesa más que la precisión global. RF + SMOTE obtiene el F1 más alto de los tres (0.425 vs. 0.419), pero el proyecto lo excluye deliberadamente de la comparación de “mejor modelo desplegable” (`src/models.py`, función `entrenar_y_evaluar_todo`, línea 564, que descarta expresamente el candidato `rf_smote` antes de fijar el mejor modelo): se entrena

únicamente como referencia académica del efecto del sobremuestreo sobre el recall, no se serializa como artefacto de despliegue, y su mejora de F1 sobre `rf_classweight` (+0.006) no compensa la complejidad añadida de mantener en producción un pipeline de SMOTE. El modelo ganador y efectivamente servido por el Panel 2 es, por lo tanto, `rf_classweight`, coherente entre `models.py`, `metrics.json` y `panel_predictivo.py`.

La interpretabilidad se resuelve con SHAP (TreeExplainer): el *summary plot* (Figura 2) muestra qué contaminantes mueven más la predicción a nivel global, y el *force plot* (Figura 3) descompone una predicción puntual. Ambos dan sentido físico a la decisión del modelo – relevante frente a la pregunta de causalidad vs. correlación que el curso exige poder responder.




Figura 1: Matriz de confusión del modelo ganador (`rf_classweight`).




Figura 2: SHAP summary plot (importancia global de features) del modelo ganador.

El caso de la Figura 3 es una hora real del set de test (estación San Juan de Lurigancho, 2020-08-28 21:00, PM2.5 **medido** = 33.0 $\mu\text{g}/\text{m}^3$, por debajo del ECA de 24h). Con entrada `pm_10=82.2`, `so2=12.3`, `no2=40.3`, `o3=2.4`, `co=717.6`, el modelo predice una probabilidad de 0.284 para “alta contaminación” – por debajo del umbral de 0.5, así que clasifica correctamente esta hora como *baja*, coincidiendo con la etiqueta real. El mayor empuje hacia “baja” (azul) viene de `pm_10` y, en menor medida, de `co`: aunque




Figura 3: SHAP force plot para un caso puntual real: estación San Juan de Lurigancho, 2020-08-28 21:00.

el PM10 está elevado (82.2), su efecto SHAP en este caso puntual empuja hacia la clase baja, no hacia la alta – evidencia de que el modelo no aplica un umbral univariado simple sobre un solo contaminante, sino que pondera la combinación completa de los 5. Lo único que empuja hacia “alta” (rojo) es el O₃ muy bajo (2.4) y el NO₂ moderado (40.3), pero no alcanza para revertir el resultado.

4.3 Pronóstico: naive estacional vs. Holt-Winters vs. SARIMA

Para el PM2.5 mensual se compararon tres modelos sobre un hold-out cronológico de 12 meses (sin barajar, para no filtrar futuro hacia el pasado):

Modelo	MAPE	RMSE	MAE
Naive estacional (ganador)	8.18%	2.34	2.04
SARIMA	11.30%	3.26	2.91
Holt-Winters	11.86%	3.30	3.03

Tabla 4: Comparación de modelos de pronóstico, serie mensual agregada “TODAS” las estaciones, $n = 67$ meses, hold-out=12.

Conclusión razonada. El baseline más simple (repetir el valor del mismo mes del ciclo anterior) supera a SARIMA y Holt-Winters en esta serie. Con solo 55 puntos de entrenamiento y una estacionalidad mensual regular (el “invierno limeño”), los modelos con más parámetros no logran capturar patrón adicional que no esté ya explicado por la estacionalidad pura, y terminan sobreajustando ruido de corto plazo. Esta es una conclusión honesta del proyecto, no una limitación oculta: un modelo más sofisticado no siempre es la mejor respuesta cuando la serie es corta y muy estacional.

El pronóstico final (6 meses, mayo–octubre) se reajusta con el modelo ganador sobre toda la serie disponible –no solo sobre el tramo de entrenamiento del hold-out– y proyecta valores entre **25 y 31 $\mu\text{g}/\text{m}^3$** . Como es un promedio mensual, el umbral que corresponde para juzgarlo es el ECA **anual** de largo plazo ($25 \mu\text{g}/\text{m}^3$, Sección 1), no el de 24h ($50 \mu\text{g}/\text{m}^3$): contra ese umbral correcto, el pronóstico queda al borde o ligeramente por encima, no cómodamente por debajo – una señal de alerta temprana concreta para la temporada de invierno limeño.

5 Narrativa: de la complicación a la resolución

(a) Situación

El dataset crudo de SENAMHI cubre 10 estaciones de monitoreo de Lima Metropolitana con registros horarios de 6 contaminantes (PM10, PM2.5, SO₂, NO₂, O₃, CO). Tras la limpieza, la ventana analizada es 2014-10-01 a 2020-09-30, con 514,680 filas hora-estación.

(b) Complicación real en los datos

1. **Vacío estructural anterior a octubre de 2014.** PM2.5 tiene entre 50% y 58% de nulos antes de esa fecha, y recién baja a 22.7% de nulos en octubre de 2014. No es un hueco puntual: es

la propia serie histórica siendo demasiado incompleta para imputar con confianza. Por eso el proyecto define `FECHA_CORTE = 2014-10-01` y descarta todo lo anterior en vez de rellenarlo (`src/preprocessing.py`, líneas 37–43).

2. **Apagón de sensor de más de un año en SAN MARTIN DE PORRES.** Esa estación concentra dos huecos largos: de 2018-08-06 a 2019-05-16 (~9.4 meses) y, más grave, de 2019-07-10 hasta el final de la serie (2020-09-30), ~15 meses consecutivos sin dato medido. En total, 42.5% de las horas de esa estación son imputadas por climatología (contra 37.8% de imputación a nivel global del dataset) – sus últimos 15 meses de serie no son observación real, sino relleno estacional estimado a partir de años previos.
3. **Fuga de autocorrelación temporal en la validación.** Un split aleatorio fila-por-fila del dataset horario deja horas del mismo día calendario repartidas entre train y test. Como los contaminantes de horas consecutivas del mismo día están fuertemente correlacionados, esto infla de forma optimista el ROC-AUC/F1 reportado – el modelo “ve” parcialmente el día que se le pide predecir.
4. **Desbalance de clases en la etiqueta de alta contaminación.** Solo 7.9% de las horas medidas superan el ECA de 24h; un modelo entrenado sin ajuste alguno tendería a ignorar la clase minoritaria, que es precisamente la que importa para una alerta.

(c) Resolución con técnicas del curso

1. El vacío estructural (b.1) se resuelve por diseño: se recorta la ventana de análisis en vez de imputar sobre una señal demasiado ruidosa para confiar en ella.
2. El apagón de SAN MARTIN DE PORRES (b.2) se resuelve con un pipeline de imputación en 3 niveles, de más a menos confiable: interpolación lineal acotada a 6 horas para huecos cortos, climatología fina (mediana por estación-mes-hora) para capturar estacionalidad, y climatología gruesa (mediana por estación-hora) como respaldo final. Cada valor imputado queda marcado en una columna `_imputado` antes de imputar, para que ningún panel del dashboard confunda dato real con relleno (visible como métrica explícita en el Panel 1).
3. La fuga de autocorrelación (b.3) se resuelve reemplazando el split aleatorio por un `GroupShuffleSplit` agrupado por día calendario (`src/models.py`, función `dividir`, líneas 132–156, aplicado en la línea 536–537): todas las horas de un mismo día caen enteras en train o en test, nunca repartidas.
4. El desbalance (b.4) se resuelve comparando explícitamente tres estrategias (`class_weight`, `scale_pos_weight`, SMOTE) y eligiendo por F1 de la clase minoritaria en vez de accuracy (Sección 4.2), documentando por qué SMOTE no se despliega pese a ganar por F1 crudo.

(d) Impacto: qué decisión real habilita

Con estas resoluciones, el proyecto entrega tres piezas accionables: (1) una clasificación de riesgo por hora con $F1 = 0.419$ y explicación SHAP, útil como insumo de un sistema de alerta temprana explicable, no solo una etiqueta binaria; (2) un pronóstico mensual con 8.18% de error que proyecta 25–31 $\mu\text{g}/\text{m}^3$ para el próximo invierno limeño –al borde o por encima del ECA anual–, suficiente para anticipar con semanas de antelación el pico estacional y planificar campañas de salud pública o restricciones vehiculares estacionales; y (3) una segmentación de estaciones (silueta = 0.330 con $k = 2$) que identifica objetivamente 5 zonas prioritarias (ATE, Puente Piedra, San Juan de Lurigancho, Santa Anita, Huachipa) para concentrar inversión en monitoreo y mitigación, en vez de tratar Lima como una sola zona homogénea.